

BridgeTree：当前问题与下一步方案

PersonaMem-v1 32k · 版本与实验复核 · 2025-2026 顶会研究

报告版本：2026-09-15 / R1 | 代码包版本：0.1.0
结果截止：2026-09-15 17:30:19（北京时间，下载归档）
审计性质：只读诊断与方案建议；不是新版本实现或新一轮实测

当前最需要解决的不是“搜索量不够”，而是三个独立问题：
评分目标与历史证据充分性不一致；有限预算下跨目标搜索覆盖不足；reranker 服务失败及评测归因不清。

实验现状

已处理任务	成功执行	执行失败	成功输出答对
493	377	116	232

总计划为 589 题 × 5 方法 = 2,945 个任务，目前处理 16.74%。任务执行成功不等于答对；当前仍有 2,452 个任务未进入最新 outcomes 快照。报告不声称这是服务器此刻的实时进度。

核心结论

- 质量：**activation 与 dense 共同成功的 61 题中，分别答对 36 / 41 题；纠正 5 题、损害 10 题。点估计不利，但样本小且存在非随机失败，不能宣称总体显著劣于 dense。
- 机制：**三个详细反例中，关键历史都已进入候选库，却被负集合边际拒绝。602 条交互、311 次选择比较的算术复算正确。
- 可靠性：**三个搜索方法的 295 个已处理任务中，116 个最终失败，均未调用生成器；所有任务级重试均未恢复。

建议决策

保留当前运行作基线。先补齐模型身份与失败请求日志；先做冻结候选库的选择器消融，再做同预算跨目标调度消融。外部对照首选 **RF-Mem (ICLR 2026) 启发式版本**，其公开 32k 数据与本实验逐字节一致。

阅读导航：版本 p.2；结果 p.3；失败成本 p.4；代码机制 p.5-8；论文 p.9；修改方案 p.10-12；日志与复现依据 p.13-15。

01 当前版本与实验协议

软件版本、Git 提交和运行内容身份需要分开记录。pyproject.toml 的发布版本是 **0.1.0**；本地 HEAD 为 39efab3dd547，工作树有既有未提交改动。重新计算的**本地源码聚合哈希与归档运行完全相同**，因此本报告所引用实现可对应这次运行。

项目	归档 / 当前核验值
运行目录	outputs/chain-skip-failed/ dependency_20260914_124930_2365962
代码身份	source hash: 3a55adcae46c... 包含 src/bridgetree、reference、configs、scripts、pyproject.toml；不是单一 Git commit
数据	PersonaMem-v1 · 32k · 589 题 revision: fd7c30f071d5...
可见历史	每题 messages[:end_index]; user_assistant_pair; include_system_persona=true
方法	dense / dense_rerank / activation / context_marginal / activation_fixed_pool
预算	初始 dense 12；初始扩展宽度 4；proposal 4；ANN 总上限 36；搜索与选择各 512 个唯一集合配额
生成	deepseek-v4-flash；temperature=0；输出上限 512；完整输入估算上限 8192 tokens
评分与编码	qwen3-embedding-8b；reranker 为 pointwise / unit_interval；batch_size=32，输入估算上限 8192
训练与协议	optimizer_steps=0；weights_updated=false；protocol_role=all_data； protocol_hash=not_defined

优先补齐的复现信息

归档只证实生成器 API 配置名。用户所述 284B / INT8 及实际 checkpoint、服务版本、thinking 模式没有被归档字段证实；reranker 的 model 字段为空。下一版必须固定实际部署身份，不能从 API 别名推断模型能力。

本报告不改动版本号或实验配置。完整 source/config/data hash、原始文件 SHA 与归档校验和见 p.14。文中的 fixed_pool 是 activation_fixed_pool 的表格简称。

02 实验结果：先看分母，再谈优劣

优先采用 493 份逐任务 outcomes。归档中的 summary/current 都是 490 条，少了三条成功但答错的最新结果，属于非原子快照刷新差异；不是本次将重试重复计入成绩。

方法	处理	成功	正确	失败	成功样本正确率	已处理任务正确率 ¹
dense	99	99	65	0	65.66%	65.66%
dense_rerank	99	99	66	0	66.67%	66.67%
activation	99	61	36	38	59.02%	36.36%
context_marginal	98	57	31	41	54.39%	31.63%
fixed_pool	98	61	34	37	55.74%	34.69%

¹ 正确数 / 已处理任务数，执行失败计入分母但不是“模型回答错误”。成功样本正确率 = 正确数 / 成功执行数。未处理任务不在这两个分母中。

与 dense 的问题共同成功配对

对比方法	共同题数	dense / 方法 答对数	纠正 / 损害	净差 百分点
dense_rerank	99	65 / 66	2 / 1	+1.01
activation	61	41 / 36	5 / 10	-8.20
context_marginal	57	35 / 31	3 / 7	-7.02
fixed_pool	61	40 / 34	7 / 13	-9.84

“纠正” = dense 错而该方法对；“损害”反之。每行使用各自共同成功题，不可将不同行分母混在一起。

五种方法全都成功的共同集合仅 **44 题**：dense、dense_rerank 各对 30；activation 对 24；context_marginal 对 25；fixed_pool 对 24。说明当前差距不完全由 HTTP 失败造成，但不能排除共同成功筛选产生的偏差。

统计解释

样本覆盖 99 个问题、4 个 persona (0、1、3、6)，不是全体 589 题的随机样本。三个搜索方法相对 dense 的探索性精确 McNemar p 值约 0.302 / 0.344 / 0.263，未做多重校正及 persona 聚类处理；没有统计证据宣称稳定优劣。

整体 successful_accuracy=232/377=61.54% 只是五方法执行汇总，不代表一个模型的独立测试分数。
232/2945=7.88% 是未完成实验的固定分母准确率下界；不能拿它当最终 accuracy。

03 可靠性与成本：先定位 reranker

116 / 295 = 39.32% 的搜索方法任务最终失败。全部失败发生在生成之前，因此这些失败不能归因于 DeepSeek 答题能力或生成端 INT8 量化。

失败类型 / 阶段	已核实数量
最终 HTTP 500 / TimeoutError	112 / 4
dependency_search / selection	83 / 33
任务级失败尝试	116 个任务 × 3 次 = 348 条
任务级重试恢复	0 个；232 次追加尝试均未恢复
尚有 ANN 预算的最终失败	77 个；所有失败仍有集合评分预算

116 个任务的三次尝试都停在相同 ANN / scored_sets 计数。后两次依赖缓存快速重走前缀，只剩一次 reranker 逻辑调用。这与“某个剩余请求稳定触发失败”相容，但未证明是同一个请求体、超长输入或 OOM。

HTTP500 已经拆分到单个 集合文档 仍失败；一个集合文档可能包含多条记忆。日志缺少失败集合 ID、真实 token 数、响应关联 ID 和服务端异常栈，不能把“单文档”误读成“单条短记忆”。

成本必须累计所有尝试

方法	全部尝试小时	成功任务中位秒
dense	0.694	25.11
dense_rerank	0.257	9.61
activation	9.765	369.40
context_marginal	4.531	140.52
fixed_pool	2.960	73.32

去重后的 725 次 executor 调用合计 **18.207 小时**，其中失败消耗 7.608 小时（41.79%）。只加 outcomes 的最近一次成本，会漏掉约 6.66 小时。额外任务退避约 2.417 小时是按配置推算，不是等待事件实测。

成本口径

dense 承担共享 memory embedding；后执行方法复用大量 persistent score cache。表中时延不是算法固有速度排名，也不是运行墙钟时间；不包含全部外层等待。逻辑 token 估算不是账单 token，也不是单请求长度。

04 代码问题一：代理目标与证据效用错位

原始 query

→

记忆集合串联

→

相关性 $R(q, S)$

→

正边际添加

实现将完整记忆集合序列化成一个文档，与原始 query 一起送入 pointwise reranker。元信息与 user/assistant 原文保留，没有独立检查“这些历史是否足以完成个性化回答”。选项只在最终生成阶段出现。

$$\Delta(B | S) = R(q, S \cup B) - R(q, S)$$

只接受最大且严格为正的 Δ ；否则 no_positive_marginal 停止。

已证实的行为

- 三个案例的关键历史都已召回、归档且可放入预算；选择器仍因负边际拒绝它们。
- 末轮所有边际严格小于零，既不是阈值太高，也不是小数显示舍入成零。
- 0.999 只是服务返回的相关性值，不是 99.9% 答对概率。unit_interval 只校验取值范围，没有证据充分性校准。

机制缺口，不是已发现的减法 bug

当前 query 的近似复述可能取得极高分，却没有提供 query 之外的历史事实。另一方面，过去的退出原因或使用习惯可能决定正确回答，却拉低集合分。将“更相关”直接用作“更有用”的唯一准则，存在清楚的失败反例。

此外，选择器只有添加，没有移除、替换或重新选择先前项。早期高分选择可能锁定后续轨迹；但在同一失配目标上增加搜索复杂度，也不保证找回有用证据。

搜索同样受这一代理分数影响

$$A(e, G | P) = R(P \cup G \cup \{e\}) - R(P \cup G) - R(P \cup \{e\}) + R(P)$$

正 activation 只说明评分上的条件交互；不保证集合边际为正，更不等于真实依赖或因果关系。读书会例中 38 个正 activation 有 2 个对应负 context_marginal。

源码：dependency_scoring.py:576、799；dependency_experiment.py:1743；dependency_search.py:635、1244、1282。对固定候选库作严格单调 logit 变换，不改变选择边际的正负及本轮 argmax，不能单独修复此选择机制。[R1]

05 三个反例：事实已到达，最后被排除

这三个案例用于定位失败链路，不用于估计全数据发生率。记忆编号是各自 question_id 内的局部编号。完整 task / question 标识见 p.14；原文事实已按固定数据前缀重新构建核验。

绘画：保留“想重新上课”，遗漏“过去为什么离开”

m39 描述画室课程的僵化限制了自由实验；位于初始 dense 第 4 名。最终却保留 m11（曾报名）与 m81（当前重返课程的想法）。最终集合分 0.9997326174，补入 m39 后为 0.9988752425， $\Delta = -0.0008573748$ 。dense 答对，activation 答错。

音乐：保留观看演出，遗漏“自己用软件制作音乐”

m05 是家庭录音室制作习惯，m27 明确提到新软件与数字音频工作站，初始 dense 排名分别为 1、9。最终只选 m06+m08；加入两条事实中的任意一条都会降分。

候选操作	原分	加入后	边际
音乐：补 m05	0.99287857	0.94580127	-0.04707730
音乐：补 m27	0.99287857	0.97404264	-0.01883593
读书会：补 m37	0.99924459	0.99629275	-0.00295185

读书会：当前重返想法压过过去退出原因

m37 解释退出是因为讨论过于学术化、正式，削弱情感交流；初始 dense 排名第 3，进入过多个 bundle。最终只选 m73（当前想重新加入）。dense 答对，activation 答错；context_marginal 也只选 m73、哈希相同，却答对。

核验项	绘画	音乐	读书会
交互记录 / 选择比较	192 / 117	250 / 83	160 / 111
末轮负边际 / 比较总数	38 / 38	40 / 40	55 / 55
最终估算输入 tokens	1100	971	716
不可行比较 / 不完整轮	0 / 0	0 / 0	0 / 0

所有比较都在容量内，生成输入上限均为 8192。少选不自动等于错误；这里的关键是有用历史被明确拒绝，且补回能否改善答案仍需控制生成波动的实验。

06 代码问题二：跨目标调度缺少保障

状态是 (固定 target, premise 集合)。扩展增加前提，不切换目标。所有初始根以 priority=0 入堆，平局按 memory_id 排序；任何正信号后继都优先于未访问根。有限预算下，其他目标可能长期没有机会。

案例	初始根	已访问目标	24 条状态中的前提深度分布
绘画	15	1 (m2)	0 层 1；1 层 10；2 层 13
音乐	16	4	0 层 4；1 层 20
读书会	19	1 (m3)	0 层 1；1 层 16；2 层 6；3 层 1

三个案例均为初始阶段消耗 13 次 ANN，剩余 23 次条件 ANN；日志包含 23 个发生测量的状态与最后一次预算拒绝状态。24 条状态不是 24 次完整有效展开，更不是一条 24 层长链。

准确描述：局部有分叉，跨目标扩散不足

- 目标 e → 前提 {a} → 前提 {a,c} 或 {a,d}
- 目标 e → 前提 {b} → 其他组合
- 目标 f、g、h 仍在零优先级队列中等待

绘画根 m2 一次产生 10 个正后继；读书会根 m3 一次产生 17 个。音乐主要是几个根的一层星状分支，而不是深链。尚未作为 target 展开的记忆仍可作为 premise、初始 singleton 或最终候选出现，不能说它们完全没被看到。

额外限制

池外新候选只会归档为单例、参与已有目标的前提组合，不会自动成为新的独立根。新候选数、bundle 数或 visited_state_count 均不能替代“不同目标获得多少预算”的覆盖统计。

待测修改

在相同 ANN 与评分总配额下，测试跨目标轮询或根覆盖预留配额，目标内部仍按 signal 排序。首轮根可能测量整个初始池，因此不能只约束 ANN 而忽略评分预算。池外候选晋升为根是另一项改动，应单独消融。

源码：dependency_search.py:271、302、710、786；tests/test_dependency_search.py:235 明确测试正后继优先。现象对应设计取舍，不是代码意外违背既定规则；广覆盖会牺牲局部深入，准确率收益尚未验证。

07 其他代码与实验控制问题

dense_rerank 对照没有改变最终记忆集合

99 / 99 共同题中，两者都保留相同的 12 条记忆。生成器构造输入前又统一按时间排序，因此当前设置下 rerank 的顺序改变不会保留到 reader。65 对与 66 对的差别不能直接解释成重排收益；7 个标签变化中只有 2 次纠正、1 次损害。

下一版应先记录真实请求哈希。如果需要有效的筛选型 rerank 基线，可预先定义更大的初始候选集，再选相同 k 条；这是一项新的基线配置，不应悄悄改写当前结果。

context_hash 不等同于线上请求身份

哈希包含 selected_ids 的原始顺序，而请求使用规范化时间顺序。不同 hash 不证明发给模型的消息不同；反之，搜索方法已有相同 hash 却一对一错的例子。temperature=0 不能保证远端部署完全确定。

扩展后的有效差异很小，不能用过程计数代替收益

共同成功对比	共同题数	最终集合相同
activation / fixed_pool	55	49 (89.1%)
activation / context_marginal	46	36 (78.3%)

activation 的 61 个成功任务中，42 个最终只保留 0—2 条记忆，完整输入中位数 1147 tokens；dense 为 4722。压缩可能有价值，也可能丢证据，需要按“证据是否被保留”与正确率共同评估，不能把 token 少本身视为失败。

失败批次的可观测性与部分缓存

reranker 拆分后的成功子批结果，若另一个子批失败，可能尚未返回 scorer 并写入持久缓存；完整评分事件也只在调用成功后追加。下一版可独立持久化已验证的 pointwise 单文档结果，并写 pre-call 事件，但不得提交不完整选择轮次或给失败伪造分数。

验证范围

当前本地离线测试：search/scoring 42 passed, clients 21 passed。证明的是公式、缓存与控制流等被测行为；未运行新的模型调用，不证明服务稳定或代理目标正确。

源码：clients.py:185、252、738；dependency_scoring.py:833、855。reranker 模型身份缺失与失败请求追踪缺失应列为工程 P0；目标错位与调度不足是独立的机制问题。

08 近两年顶会：严格区分可比性

检索截止 2026-09-15；“近两年”采用正式会议年份 **2025—2026**，以会议官网、PMLR、ACL Anthology 核实身份，并阅读论文和作者代码。以下是与当前问题最相关的候选集，不声称穷尽全部工作。

论文 / 方法	正式会议	可借鉴内容	当前数据可比性
Sufficient Context [R1]	ICLR 2025	相关性、充分性、答对三者分开	不是 PersonaMem
HippoRAG 2 [R2]	ICML 2025	原文 passage 与结构检索融合	不是 PersonaMem
A-Mem [R3]	NeurIPS 2025	原文、事实描述、动态链接	原论文 LoCoMo / DialSim
MemoryOS [R4]	EMNLP 2025 主会	近期交互、主题记忆、用户画像分层	原论文 GVD / LoCoMo
RF-Mem [R5]	ICLR 2026	熟悉性与回忆路径自适应路由	32k 两文件 SHA 完全匹配

最直接的机制依据：Sufficient Context

论文将“上下文包含足够回答信息”与生成器是否答对分离。提示式 autorater 可不更新权重，但需要人工核验后才能迁移；其 selective generation 还包含 logistic regression，另有 LoRA 实验，不能把整篇论文都标成免训练。

结构不是目的：HippoRAG 2

正式题名为 *From RAG to Memory: Non-Parametric Continual Learning for Large Language Models*。它保留 passage 节点，将 dense 信息通路与图关联结合，并在过滤不到 triples 时回退 passage retrieval。这支持检验“基础事实通路是否被结构选择牺牲”，不直接证明根轮询适合 PersonaMem。

记忆表示与时序管理：A-Mem / MemoryOS

两者核心记忆写入、关联、总结可通过既有模型推理实现，无须针对本数据训练权重，但需要计入建库成本。A-Mem 链接不是因果证明；MemoryOS 的访问热度也不等于偏好生效时间。

证据边界

除 RF-Mem 外，本次没有核实这些论文原实验使用与我们相同的 PersonaMem-v1 32k 文件。后续论文中的 PersonaMem 128k 重测不能冒充当前 32k 排行榜；LoCoMo F1 也不能与多选 accuracy 直接比较。

完整官方出处、论文和代码链接见 p.15。下文工程方案是受这些研究启发的待测假设，不是论文已在本项目验证的结论。

09 下一步机制修改：先隔离，再组合

方向 A：增加独立的历史证据审计 [R1]

对固定候选池和最终集合分别判断：是否有用户相关事实、是否提供 query 之外的新信息、是否包含过去原因或明确更新、能否回溯到原文。PersonaMem query 常是陈述句，不能照抄开放域 QA 充分性提示。

第一步只作离线人工小样本审计，再验证提示式评审器与人工的一致性。离线可查看答案判断所需事实；**线上 query-only 检索与选择不得读取金标准**。若要引入答案选项感知，必须另立统一协议，不能仅给新方法额外信息。

方向 B：替换“唯一正边际”准入与停止机制 [R1, R2]

冻结候选库，对比原选择器与“预声明 dense 锚点保留 + 互补证据补充”。锚点数在独立开发集或预先规定，不按这三个反例逐题指定。另一条后续路线是覆盖约束：优先覆盖互补历史事实、避免把 query 复述当唯一证据；评分器仍可用于相关性排序，但不独自决定证据已足够。

先不加更复杂的大图、beam 或无限补文档。严格单调 logit 变换不会修复固定 archive 下的当前选择轨迹；放宽到负边际也不能在未验证的尺度上保证有意义。

方向 C：同预算多目标调度

保留部分预算访问不同根，或目标间轮询、目标内按 signal 排序。报告每个目标的 ANN、唯一评分集合和状态数。新候选晋升为根、改变 pair rescue 或替换 signal，各自单独开消融，避免无法归因。

方向 D：在确认选择损失后，再改表示 [R3, R4]

引入可追溯的个人事实字段、来源、观察时间、明确的更正 / 否定关系，同时保留原文。区分稳定画像与近期事件；不能把访问频率当有效性，也不能把消息索引当日历时间。任何 LLM 抽取字段都需要原文支持和错误监测。

防止事后调参

人工补回 m39/m27/m37 只能作为诊断实验，不是可部署算法成绩。报告中所有方案均未实现、未调用模型验证，也未承诺提高准确率。

优先顺序：工程可观测性 → 冻结候选的选择器 → 同预算调度 → 两者组合 → 表示层 / 完整记忆系统。三个已定位案例关键事实已召回，因此单纯增加检索量不是最直接修复。

10 首选复现：RF-Mem 的同数据对照

Evoking User Memory: Personalizing LLM via Recollection-Familiarity Adaptive Retrieval, ICLR 2026. [R5] 官方仓库固定 commit d6a2cb3416e8... 下的两份 32k 文件，与本实验 question / context SHA 完全一致，共 589 题。

论文 Table 1 · 32k	准确率	论文平均输入 tokens
Dense Retrieval	59.08%	3515.9
Recollection	62.14%	3711.1
RF-Mem	63.50%	3566.6
Full Context	61.29%	24657.8

这是论文内对照，不是我们的 DeepSeek 成绩。论文实现说明只称生成器为“advanced LLM”；代码默认 gpt-4.1-mini 不能反推发表表格的服务身份。论文毫秒级 retrieval time 也不是我们的端到端 HTTP 时延。

为什么适合先复现

主版本使用相似度统计 / 熵进行熟悉性与回忆策略路由，结合聚类与检索扩展，不需要额外训练权重，也没有 A-Mem 式 LLM 记忆重写成本。应排除附录的 learned gate，先移植主启发式及两个分支作为对照。

不能直接运行当前公开 driver

- 读取了每题 end_index，但主入口未据此截断共享 history；公开数据 README 明确要求截断。复现必须修正此协议缺口，不能据此反推论文表格一定泄漏。
- 代码使用 cmd_args.rag，但 argparse 没有对应参数；run.sh 是 60 组参数扫描，不是冻结配置的单次运行。
- 上游预处理会跳过 system，并丢弃无后续 assistant 的尾部 user；我们的记忆政策不同，需要在统一 harness 中明示对齐。
- 上游默认 embedding 与 Qwen3 不同，路由阈值可能失配。只允许独立开发集 / 无标签统计校准，禁止在 589 题答案上扫参取最优。

第二批：A-Mem、MemoryOS 可作模型对齐迁移基线，而不是已验证同 32k 优胜者。MemoryOS 的 get_response 默认把测试问答写回记忆，迁移时须隔离；其错误字符串也必须分类为失败，不能正常入库。

移植属于“同模型、同可见信息协议重测”，不等于精确复现论文数值。不要给本来没有 reranker 的基线额外添加 reranker；不同记忆大小不宜用强制同条数代替同 token 预算。

11 下一版实验计划与验收条件

以下是建议的新协议，不覆盖当前运行，也不把看过的错误题重新当未见测试题。先建立独立、最好按 persona 隔离的开发 / 保留评估划分；现有 99 题和三个深审案例标记为“已观察诊断集”。

阶段一：冻结候选的选择器实验

使用同一 query、历史前缀、候选 archive、规范化生成提示及模型服务，比较原选择器与预注册新选择器。人工补事实另作诊断分支，不进入正式成绩。先判断“候选有证据、最终丢证据”的比例是否下降。

阶段二：同预算 2×2 消融

实验臂	搜索调度	选择器	回答的问题
A	原调度	原规则	复核旧行为与服务波动
B	原调度	新规则	选择器单独贡献
C	多目标调度	原规则	覆盖调度单独贡献
D	多目标调度	新规则	二者组合及交互

固定 ANN 总上限 36、搜索唯一集合 512、选择追加 512，完整生成输入上限 8192；更换调度可以改变 archive，这是调度实验的真实作用，不能再称候选库完全相同。离线生成记忆与在线充分性评审若新增调用，应独立计费。

阶段三：加入外部免训练基线

先移植 RF-Mem familiarity / recollection / routed 三支；完成源码与有效参数 golden tests 后重跑。再按工程预算考虑 A-Mem、MemoryOS；HippoRAG 2 可作为结构通路的后续对照，而不是先决条件。

验收不只看一个 accuracy

- 运行身份可复查：实际 checkpoint、量化、thinking、embedding、reranker、提示与配置均固定。
- 报告全部预注册题的执行成功率、固定分母正确率、成功样本正确率和共同题配对 win/loss；失败单列，不用成功样本掩盖缺失。
- 按 persona / question_type 分层；预先约定重复生成与统计方案。同一实际请求可共享一次生成作控制实验，或重复多次估计波动，二者不能混用计费。
- 并列报告证据召回、最终保留、根覆盖、输入 token 与全部尝试成本；覆盖变广或分数变高本身不是成功标准。

12 日志与代码修改清单（尚未实施）

P0：让失败可定位、版本可追溯

在实际服务调用之前记录 request_id、阶段、任务 / 尝试、集合 ID、文档哈希、估算及服务实际 token、batch 文档数；失败时保留 HTTP 状态、关联 ID 与脱敏错误类型。服务端记录 traceback / OOM / tokenizer 或 payload 校验结果。原始个人文本与凭据不应进入公开日志。

记录实际模型标识、部署版本、量化、thinking、解码参数和 tokenizer；为最终 HTTP payload 生成规范化 request_hash，排除仅供审计的 selected_ids 顺序与传输地址等元信息。

P1：增加能判定模块贡献的统计

证据召回 / 入选率需要独立标注的诊断集。当前协议没有现成的官方 gold memory IDs，不能直接从现有过程日志计算正式 Recall；请区分人工事实审计指标与自动运行计数。

模块	应新增 / 汇总的观测	判断目标
候选检索	证据所在层：可见库 / 初始池 / 扩展池	没召回，还是召回后丢失
依赖搜索	不同根覆盖；每根 ANN / scored_sets；premise 深度；正信号分支	预算是否集中于少数目标
归档选择	证据入选率；拒绝原因；前后集合分；query 重复项；互补事实覆盖	分数变化是否牺牲历史证据
最终生成	真实 request_hash；同请求标签变化；证据充分性 × 正确性	生成波动，还是输入差异
成本可靠性	按 task_id+attempt 去重；离线/在线/重试/等待；冷/热缓存	端到端代价与失败恢复

建议涉及的实现位置

dependency_scoring.py:576 / 799 集合序列化与 pre-call 事件
dependency_search.py:710 / 786 根与后继队列调度
dependency_search.py:1244 / 1282 边际选择与停止
clients.py:185 / 252 规范化生成请求与 hash
clients.py:738 拆批失败与成功子批结果
dependency_experiment.py:1743 评分器身份及运行记录

保持失败语义

不得把失败请求的分数置零继续当正常测量；不得把不完整选择轮次提交为有效结果。若提出 dense 回退，应另命名为显式复合方法，记录 fallback，并与不回退的原方法分开汇报。

不建议当前直接提高 ANN、score 或重试次数：关键事实已召回的案例不受益于更多召回，稳定失败的请求也未因任务级重试恢复。先取得失败请求与服务端证据，再决定工程修复。

附录 A 证据身份与可复算材料

本地原始数据与运行 manifest 的两文件 SHA 一致；本地源码聚合 hash 也与运行一致。以下长哈希为准确身份，不能仅凭文件名、日期或 API 模型名代替。

身份项	完整值
运行 source hash	3a55adcae46c4bd7a1231b55736c8d381f2eac0a8ef57e5470a94c4dd6757b0c
运行 config hash	ab7c1417e7f93f27ae43ea6dd0e9aadf523a7ef162ef5f5dabfad200b0b368bf
运行 data hash	fe4b12d89ac0fc1138640df282432667227485be666b696029cb3e74f51cce49
数据 revision	fd7c30f071d5c2ee2a211506783be222d7b6002e
questions_32k.csv SHA256	cccd34cf53e0bc4d9536c04cff5ca045156d9a4e227e83327112482840bbc93c
shared_contexts_32k.jsonl SHA256	217247ebfec9e8442fc53570c795ab69f21aad08745f7de78d9beab51b122d4a
chain-audit-full.tgz SHA256	51e5a511c198a4d14799128ef6d511204582a43c2473da387a1c394642697d53
chain-audit-detail.tgz SHA256	c040e839dc5f957596cde0632d739d60769e1ec884092829460bde62c3334c80

详细案例索引

绘画 question: 17273334-b524-4398-baae-bfb459f149e0
task: 3b1003e23012d57db5e0a5bf1cf473689beef60580562ffe71d84c0dc7cd581b

音乐 question: fd81b480-5723-43fe-9fb1-d3efa0df8e49
task: dd67463ac5377f24adb34606b97ec13df4e20e72130624ae43c9c4d7d299dec2

读书会 question: d4562a36-f9aa-4dcb-9033-434e5a1a4535
task: 55de70ff2877a08d427cfbccbeb317a07625f037c72a98e72e250340f3faccfa

本报告的证据文件

experiment_evidence.json: 逐方法、逐尝试和配对清单；case_evidence.json: 三例原文事实与逐轮比较；context_evidence.json: 最终集合与生成变化。对应复算脚本为 build_experiment_evidence.py、audit_cases.py、audit_contexts.py。研究核查详见 research_mechanisms.md、research_baselines.md；均保存在报告同目录。

归档不含完整的所有题候选池 / 失败请求体；深审仅覆盖提供的三个案例。报告不推断其他题均有相同机制，也不证明当前服务器已完成或停止。未进行新的生成 / 评分服务调用。

附录 B 参考文献与使用边界

以下链接可在 PDF 内点击。会议身份以官方页面为准；预印本版本用于阅读方法细节。检索日期：2026-09-15。RF-Mem 固定代码 commit 为 d6a2cb3416e8320bcb1439921d319729aeccec8e。

[R1] Sufficient Context: A New Lens on Retrieval Augmented Generation Systems

Hailey Joren et al. ICLR 2025。

官方：<https://iclr.cc/virtual/2025/poster/30092>

全文：<https://arxiv.org/html/2411.06037v3>

代码：<https://github.com/hljoren/sufficientcontext>

[R2] From RAG to Memory: Non-Parametric Continual Learning for Large Language Models (HippoRAG 2)

Bernal Jiménez Gutiérrez et al. ICML 2025 · PMLR 267:21497–21515。

官方：<https://proceedings.mlr.press/v267/gutierrez25a.html>

全文：<https://arxiv.org/html/2502.14802v2>

代码：<https://github.com/OSU-NLP-Group/HippoRAG>

[R3] A-Mem: Agentic Memory for LLM Agents

Wujiang Xu et al. NeurIPS 2025。

官方：<https://neurips.cc/virtual/2025/poster/119020>

全文：<https://arxiv.org/html/2502.12110v11>

代码：<https://github.com/WujiangXu/A-mem>

[R4] Memory OS of AI Agent

Jiazheng Kang et al. EMNLP 2025 主会 · 25961–25970。

官方：<https://aclanthology.org/2025.emnlp-main.1318/>

全文：<https://aclanthology.org/2025.emnlp-main.1318.pdf>

代码：<https://github.com/BAI-LAB/MemoryOS>

[R5] Evoking User Memory: Personalizing LLM via Recollection-Familiarity Adaptive Retrieval (RF-Mem)

Yingyi Zhang et al. ICLR 2026。

官方：<https://iclr.cc/virtual/2026/poster/10008269>

全文：<https://arxiv.org/html/2603.09250>

代码：https://github.com/Applied-Machine-Learning-Lab/ICLR2026_RF-Mem

文献只为设计与复现提供依据。没有把跨数据集成绩混作 PersonaMem 32k 比较；没有宣称免训练意味着零推理成本；没有把公开 driver 的缺口直接归罪于发表表格。所有下一版方案仍需在统一模型、数据可见性与预算协议下验证。