

BridgeTree：诊断改造与机制重设计方向

讨论修订版 R2 · PR1—PR4 同轮交付 · PersonaMem-v1 32k

大方向已知，但具体机制尚未定稿：优先检验集合相关性是否代表证据价值，再决定是否重设计目标、选择路径或跨目标调度。

本轮边界

用户确认本轮交付代码、离线验收和 PDF，真实模型实验由用户上传服务器后执行。本轮不是 PR5：保持 legacy 评分、选择器和默认搜索行为；不训练，不加 dense 保护、Judge、新选择器、轮询或根预算。PR4 只增加默认关闭的根平局顺序消融。

工作类别	PR	性质
工程与可观测性	PR1	身份、缓存隔离、请求与失败审计
找问题与验证错因	PR2—PR3	历史回放、28格点评分、重复生成
诊断性机制扰动	PR4	只改变根之间无语义的平局顺序
主方法重设计	PR5	未实施，需依据诊断另行定义

实际执行状态

阶段	当前归档状态
score	尚未执行
generation	尚未执行
root	尚未执行

离线实际归档已恢复 24/28 个小集合分数，保留 4 个缺口。三个完整 archive 历史选择回放均匹配。假 HTTP 测试证明程序契约，不证明真实服务效果。

运行身份：7142f11ecd2207e9b5de5ce8d70e363f13ebf04507aff04ec593fc9b0e77fbb5
源码快照：b9e0c674653fcb3be2cd1a97b815bbef086c4327534ef7fa4d88cd508bb41f9e
当前模型调用结果以本报告关联归档为准；旧15页审计报告保留，不将其历史成绩当作本轮新测。

01 已经知道的大方向，与尚未确定的内容

第一优先：拆开相关性、互补性与停止判断

当前 R 同时用于集合排序、四项交互差分 and 正边际停止。相关文本不一定补充回答所需的历史原因、约束或偏好更新。拟议方向是：让相关性负责候选发现，独立研究条件证据贡献和证据缺口；这不等于已经选定一个在线 Judge。

pointwise 描述批内评分契约，unit_interval 描述范围。两者都不证明概率校准或 cardinal 效用。现有 R 明确标记 legacy_query_relevance；utility_validation_id 为空，不包装成真实证据增益。

第二优先：在目标值得优化时，再允许选择修正

当前选择器只添加、不能删除替换，而且每一步必须严格正边际。可能需要有限联合添加、回退或替换，但如果补入关键历史降低 R，更强地优化 R 也可能更坚定地拒绝历史。读书会两条记忆的全部四个子集已知，当前 m73 是该局部范围的 R 最大值；是否补 m37 能稳定改善回答仍待生成诊断。

第三优先：检验目标覆盖与深入搜索之间的分配

现象更准确地描述为少数 target 周围预算集中，不一定是一条链无限加深。浅层分支也会消耗大量预算。只改变零优先级根的顺序，可以检验词典序敏感性；不能证明轮询有效，也不能解释已入候选的关键历史为什么被拒绝。

尚未确定

如何可靠识别证据缺口；新效用是否需要新模型；是否存在正路径但 greedy 未找到；新增证据是否被生成器利用；服务是否截断或漂移。这些原因可以并存，不能只挑一个解释。

固定 archive 和可行性时，严格单调变换不改变当前选择器轨迹；它却可能改变四项差分符号及跨状态边际优先级。因此 logit 不是现成修复，搜索阶段与最终选择阶段不能混为一谈。

02 PR1：部署、请求与失败必须可追踪

模型别名与实际身份分开

新增模型/权重/部署 revision、量化、tokenizer、模板与服务版本字段；来源区分 unknown、operator_declared、server_reported、verified。verified 必须有核验依据。API 名和地址不等于权重身份，人工声明 INT8 不冒充验证。

保留旧 context_hash，复用实际 payload 身份

原 GenerationCache 已按真实请求建键；此次复用规范化函数，并补上部署 fingerprint。context_hash 继续保留来源与选择顺序含义；request_hash 描述实际 JSON；execution_hash 关联部署。embedding、reranker、generator 的缓存身份都纳入部署；未知身份限制在运行作用域，不读取身份不充分的历史共享缓存。

先落盘，再发送

请求日志记录 task/attempt/phase、逻辑调用、物理请求、拆批父子关系、原始文档 index、集合 IDs、文档 hash、token 估算与服务返回 usage。started 事件持久化后才发请求。没有真实 token 时为 null，不将 batch 总量分摊成虚假的单文档测量。

默认不记录凭据、私网地址或未经脱敏的正文。配置与显式 request_params 都递归拒绝凭据别名和嵌套 headers，保留合法工具/输出格式参数及旧同值 canonical 参数。

预算与故障语义

HTTP 重试和拆批共用物理上限，重启从已落盘 started 恢复额度。物理预算耗尽与审计写入错误必须作为诊断失败，不能被旧字符串识别误当正常集合预算停止。逻辑唯一集合额度和原算法规则不变，不填零，不提交未完成的四项测量或选择轮。

不夸大工程修复

新增审计不等于已经修好旧 HTTP500 根因，也不证明服务没有内部热切换。部分成功子批缓存不在本轮必要交付中；未测到的结果不会被补造。

03 PR2：真实历史恢复与预算感知回放

评分直接从 activation 的 P/Pe/PG/PGe 和 selection 的 base_score/combined_score 恢复，保留归档 SHA、成员、JSON位置、task 和重复观测。冲突、缺分、截断或身份错误都显式报告；不通过差分倒推或插值补分。

案例	记忆数	子集数	已知	缺口
绘画	3	8	7	m00011,m00039
音乐	4	16	13	m00005,m00006,m00027 / m00005,m00008,m00027 / m00005,m00006,m00008,m00027
读书会	2	4	4	无

三个问题分别包含自己的空集；集合身份必须包含 question_id。当前全部28项尚非完整历史评分表。若原部署不可证明一致，新测4项与旧24项混合只能是探索性表；本轮在线默认重新测全部28项并另存，不污染旧分。

四个不同问题，分别回答

1. 目标集合是否直接存在于真实 archive。
2. 是否能由真实 bundle 的并集构造；B 跨出 U 时，不能擅自使用 $B \cap U$ 。
3. 是否存在每步严格正边际且输入可行的添加路径；缺分或可行性未知时保留 unknown。
4. 原 deterministic greedy 是否找到；复用原比较、tie-break、整轮原子性及逻辑预算计数。

已完成的真实回放验收

绘画、音乐、读书会的完整 archive 回放均匹配选中集合、停止原因、初末逻辑唯一集合计费、逐轮决策及完整比较域。受限 U 模拟单独命名，不代表全 archive 的任意反事实轨迹，也不能证明全库最优。

detail archive SHA256: c040e839dc5f957596cde0632d739d60769e1ec884092829460bde62c3334c80
所有本页结果来自本地只读真实归档；network_calls=0。

04 PR3：冻结28格点与受控重复生成

公开题目投影不携带正确选项。历史按原 prefix 和可见性规则重建；评分只接收 query 和真实记忆，全部选项仅进入 reader。反事实上下文统一用已有 build_context_plan 构造，在线严格恢复 ContextPlan，不重新拼提示、重排或截断。

计划项	数量 / 上限
完整小集合评分	28
生成逻辑trial	310
每条件技术重复	10
评分物理尝试上限	84
生成物理尝试上限	930
根消融物理尝试上限	12000

默认条件为28个子集加3个历史dense上下文，共31个；每条件10次，合计310个trial。长度匹配且不含关键事实的补入对照需人工预先指定来源和理由，目前没有自动编造。若额外加入3个对照，需重新冻结为340个trial并调整预算。

重复、缓存与续跑

按 repeat block 预先打乱条件顺序。不同 repeat 绕过响应缓存，发送实际请求；同一 trial 续跑恢复已落盘成功或终止失败，即使 outcome 尚未原子提交也不额外调用。只有可重试且额度未耗尽的失败可以继续。不因答错、解析失败或暂时有利的结果增加样本或提前停止。

失败重试不是新 repeat；超时可能已在服务端执行，结果未知要留档。物理上限是传输尝试约束，不是账单 token。真实服务是否存在内部缓存或调度相关性，不能由客户端请求数单独证明。

评价边界

gold 只在独立评价阶段读取。报告固定 trial 分母、成功输出分母、解析失败、标签分布及相对原选择的分块配对。三个事后案例重复10次仍是三个案例，不是正式 benchmark 准确率。

05 PR4：仅根平局顺序消融，默认关闭

默认 legacy_lexical，保持旧 heap 顺序。seeded_hash 只改变 priority=0 且 premise 为空的初始根相对顺序；正信号后继仍优先于未访问零根，非根平局顺序不变。

严格固定的内容

不重命名 memory ID，不打乱初始候选测试序列，不改记忆文本、集合序列化、激活公式、pair rescue、ANN 和逻辑集合预算。SHA 排序不依赖 Python hash、全局 RNG 或进程种子。默认 trace/archive/selection 通过修改前 golden 对照。

预先声明的执行矩阵

三个案例分别执行 legacy 和 seeds [7, 19, 43]，共 12 次搜索；全部种子都报告，不挑选最好种子。每次使用原始搜索和最终选择器，冻结完整 reader 输入但不调用生成器。

实际追踪字段

根排序和 pop 顺序、每个 target 的状态数与深度、首计 ANN/唯一集合成本、未访问根、archive 和最终集合 hash、外部候选进入多记忆 bundle 和最终上下文的比例；跨 seed 报告集合相等性与 Jaccard。缺失选择结果保持 null。

若搜索已完成而选择失败，保留完整搜索结果及已提交选择轮，不能把两阶段都改成失败。物理传输预算耗尽记录为外部执行失败，不宣称算法正常结束。

这不是新的调度机制

没有轮询、根预算保留或覆盖保证。种子敏感说明有必要研究调度，不等于某个种子提高了方法质量；共享缓存下时延仍受方法执行顺序影响，逻辑预算才是受控维度。

06 可执行交付与独立验收

分开提交，不混入原有工作树改动

ee39aa4 PR3: recover terminal failures and finalize diagnostic report
252e503 PR4: add opt-in root tie sensitivity and end-to-end tracing
cfbcc87 PR3: add frozen diagnostic scoring and repeated generation trials
9e301b1 PR2: recover historical set scores and replay budgeted selection
c03f959 PR1: freeze deployment identities and audit model requests

PR1-PR4 为四项独立改造；PR3 后续提交只补失败恢复回归，并非 PR5。以上均为本地提交，未创建远程 PR。

测试不仅在当前工作树运行，也在各提交独立 detached worktree 运行，确认导入隔离源码，不依赖后续PR或用户未提交修改。历史skip-failed工作区改动保留。

独立验收产物	测试数	失败/错误
full-isolated	461	0
pr1-isolated	143	0
pr2-isolated	81	0
pr3-isolated	81	0
pr3-recovery-isolated	469	0
pr4-isolated	79	0

执行入口

```
python -m bridgetree diagnostic-plan --config CONFIG --output-dir RUN
python -m bridgetree diagnostic-analyze --run-dir RUN
python -m bridgetree diagnostic-score --run-dir RUN --config CONFIG
python -m bridgetree diagnostic-generate --run-dir RUN --config CONFIG
python -m bridgetree diagnostic-roots --run-dir RUN --config CONFIG
python -m bridgetree diagnostic-evaluate --run-dir RUN --gold-source CSV
python -m bridgetree diagnostic-report --run-dir RUN
```

三个在线入口默认只展示清单；只有显式 --execute 才调用，并且必须通过身份、源码与预算门禁。--resume 不重置额度。完整命令与独立测试见 docs/diagnostic_runbook.md。

统一 JSON 报告连接 manifest、历史/新评分、重复生成、根trace、评价和失败。PDF是该状态的可读汇总，不替代原始归档。

07 诊断后的决策门，与服务器后续执行

得到的证据	下一步应改什么
补入历史稳定有益，却降低R	优先修改评分目标或撤销当前效用解释
更好组合R更高，但archive不可构造	单独研究组合提议
存在正路径，greedy却走错	单独研究联合添加、有限回退或替换
事实在可见库但未召回	检查query、检索域与目标覆盖
证据已充分但重复生成仍错	检查reader输入、任务指令和利用能力
请求漂移、截断或服务不稳定	先处理部署/服务一致性，勿据此调公式

不能同时更换目标、选择器、调度器再猜收益来源。下一版新效用必须定义清楚：提供序关系、充分性标签还是可比较的差值；不能把未校准Judge打分直接塞入四项公式。dense锚点只能作为另命名的对照，不能证明条件机制被修好。

待用户在服务器执行的实验

在线阶段	状态
score	尚未执行
generation	尚未执行
root	尚未执行

本机网络不能调用模型；上述实验不再阻断本轮代码与 PDF 交付，也没有被记作已完成。上传服务器后，修改诊断 YAML 的归档/数据路径和私有部署覆盖配置，填写真实 revision 与来源，并建立新的 manifest；不要直接续跑本机冻结目录。

服务器须确认服务可用且实验期间不热切换。安装 Python 依赖即可执行诊断，不需要 Chrome 或 PDFKit；具体部署步骤见运行手册。本报告不宣称获得线上成功率或实现 PR5。

旧24分、新测28分、技术重复和根种子消融分别归档。生成结果出来后，应更新fresh格点分析和分块配对，再更新统一报告/PDF，而不是回写历史归档。

本报告关联：/Users/mao/projects/bridgetree_preference_rag/outputs/diagnostics/2026-09-15-pr1-pr4-delivery
完整要求：docs/diagnostic_implementation_requirements.md
结论范围：同一PersonaMem-v1 32k历史的事后机制诊断；不是全体589题的正式方法排名。